



Méthodes en apprentissage automatique

Introduction aux réseaux de neurones

Pierre Magistry – ERTIM

salle L0.1, S1 2026

TALA536B

Pierre Magistry –
ERTIM

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les losses

fonctions de loss

Descente de gradient

Outline

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les *losses*

fonctions de loss

Descente de gradient

TALA536B

Pierre Magistry –
ERTIM

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les *losses*

fonctions de loss

Descente de gradient

Objectifs du cours

Comprendre et manipuler les notions clefs des réseaux de neurones

- ▶ ouvrir la boîte noire
- ▶ connaître différents types de couches, et autres composants essentiels
- ▶ savoir comment les entraîner et les évaluer
- ▶ comprendre comment ils transforment les données

Modalités d'évaluation

- ▶ Contrôle continu intégral
- ▶ Code à lire ou compléter en TP, **quizz en début de cours**
- ▶ Projet de fin de semestre (code + **mini article**)

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les losses

Fonctions de loss

Descente de gradient

Introduction (2)

TALA536B

Pierre Magistry –
ERTIM

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les losses

fonctions de loss

Descente de gradient

Info pratiques

- ▶ Gitlab et Moodle
- ▶ supports de cours, codes de démo
- ▶ matériaux supplémentaires **importants**
- ▶ Un dépôt git pour le cours, une branche à votre nom pour les rendus.

Outline

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les *losses*

fonctions de loss

Descente de gradient

TALA536B

Pierre Magistry –
ERTIM

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les *losses*

fonctions de loss

Descente de gradient

Pour vous, qu'est-ce que...

- ▶ l'intelligence artificielle
- ▶ une intelligence artificielle
- ▶ l'apprentissage automatique
- ▶ l'apprentissage profond (*deep learning*)

Et le TAL dans tout ça ?

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP


Au delà du perceptron

Quelques mots sur les losses

fonctions de loss

Descente de gradient

Vue d'ensemble du domaine



TALA536B

Pierre Magistry –
ERTIM

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP


Au delà du perceptron

Quelques mots sur les losses

fonctions de loss

Descente de gradient

l'IA générative et les LLMs dans tout ça



TALA536B

Pierre Magistry –
ERTIM

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les losses

fonctions de loss

Descente de gradient

Le corpus d'entraînement

- ▶ Comment on le construit ?
- ▶ Comment on évalue ?
- ▶ **Comment représenter les données ?**

On se focalisera sur le dernier point, mais n'oubliez pas le reste pour autant !

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les losses

Fonctions de loss

Descente de gradient

Qu'est-ce que l'apprentissage automatique ?

Qu'est-ce que "apprendre" ? Comment l'automatiser ?

TALA536B

Pierre Magistry –
ERTIM

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les losses

fonctions de loss

Descente de gradient

L'apprentissage automatique, plus formellement

TALA536B

Pierre Magistry –
ERTIM

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les losses

Fonctions de loss

Descente de gradient

cf. Tom Mitchel « Machine Learning » 1997, chapitre 1

Definition : A computer program is said to **learn** from experience E with respect to some class of tasks T and performance measure P , if its performance at tasks in T , as measured by P , improves with experience E .

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les losses

fonctions de loss

Descente de gradient

Mathématiquement ?

C'est découvrir (« apprendre ») les poids d'une *fonction paramétrée* à partir de données.

$$f(\textit{observation}) = \textit{prediction}$$

$$f(x) = y$$

$$f(x, \theta) = y$$

$$f(x, W, b) = \sigma(x \times W + b) = y$$

$$f(x, W, b) = \sigma\left(\begin{bmatrix} x_1 & x_2 & \cdots & x_n \end{bmatrix} \times \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_n \end{bmatrix} + b\right)$$

Outline

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les *losses*

fonctions de loss

Descente de gradient

TALA536B

Pierre Magistry –
ERTIM

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les *losses*

fonctions de loss

Descente de gradient

Architectures et couches

- ▶ MLP
- ▶ Plongements
- ▶ RNN, CNN
- ▶ Attention et transformers
- ▶ GNN

Applications

- ▶ Classification
- ▶ Création de plongements
- ▶ Étiquetage de séquence
- ▶ Génération de séquence

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron


Quelques mots sur les losses

fonctions de loss

Descente de gradient

Une époque formidable

<https://news.cornell.edu/stories/2019/09/professors-perceptron-paved-way-ai-60-years-too-soon>



Mark 1 Perceptron (1958)
à comparer aux LLM
et surtout aux frameworks :

- ▶ **Keras**
- ▶ pytorch
- ▶ tensorflow
- ▶ jax
- ▶ ...
- ▶ CuDNN
- ▶ Cuda
- ▶ GPU, TPU, NPU...

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron


Quelques mots sur les losses

Fonctions de loss

Descente de gradient

Niveaux d'abstraction du deep learning

Niveau d'abstraction croissant



Chaque couche masque la complexité de celles situées en dessous ; plus on monte, moins il faut de code pour un même résultat.

Le semestre en une figure




Figure 1.9 The loss score is used as a feedback signal to adjust the weights.

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les losses

Fonctions de loss

Descente de gradient

Notre nouvelle routine

1. charger le corpus
2. transformer le corpus
3. concevoir un modèle
4. entraîner le modèle
5. évaluer
6. recommencer (où ?)

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les losses

fonctions de loss

Descente de gradient

Outline

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les *losses*

fonctions de loss

Descente de gradient

TALA536B

Pierre Magistry –
ERTIM

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les *losses*

fonctions de loss

Descente de gradient

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les losses


fonctions de loss

Descente de gradient

Perceptron et apprentissage


- Décrire un perceptron
- Comment prend-il une décision ?
- Comment apprend-il ?

Neurone biologique



source Nicolas Rouvier, pages Wikipedia du neurone

Neurone artificiel



Comment un perceptron apprend

Voir le notebook cours1 sur le git.

TALA536B

Pierre Magistry –
ERTIM

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les losses
fonctions de loss

Descente de gradient

Exemple simpliste sur données réelles

TALA536B

Pierre Magistry –
ERTIM

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les losses

Fonctions de loss

Descente de gradient

Tâche d'identification de la langue


- ▶ seulement deux langues eng/deu
- ▶ hypothèse basique (nombre de 'en' et 'th')
- ▶ réseau minimaliste (perceptron)

Hypothèse

On remarque que th est plus fréquent en anglais tandis que en est plus fréquent en allemand.

On va construire notre système en supposant que les fréquences de ces deux bigrammes suffisent à distinguer les langues.

Un premier modèle



(voir l'implémentation en keras dans le notebook)

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les losses

fonctions de loss

Descente de gradient

Outline

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les *losses*

fonctions de loss

Descente de gradient

TALA536B

Pierre Magistry –
ERTIM

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les *losses*

fonctions de loss

Descente de gradient

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les losses

fonctions de loss

Descente de gradient


Pourquoi Marimo ?

- ▶ Outlines
- ▶ Documentation
- ▶ Dépendances entre cellules
- ▶ Scratchpad pour débbugger
- ▶ App View et Diapo
- ▶ IAgén (?)

```

1 # Construction du perceptron en Keras
2 model2 = Sequential([
3     keras.layers.Input(shape=(3,)),
4     Dense(8, activation='tanh'),
5     Dense(1, activation='sigmoid')
6 ])
7
8 # Compilation du modèle
9 model2.compile(
10     optimizer=SGD(),
11     loss='binary_crossentropy',
12     metrics=['accuracy']
13 )
14
15 # Entraînement du modèle
16 model2.fit(X3_lang, y_lang,
17           epochs=10,
18           verbose=1,
19           shuffle=True,
20           validation_split=0.2)
21
22 # pseudo-évaluation du modèle
23 loss_keras2, acc_keras2 = model2.evaluate(X3_lang, y_lang, verbose=0)
24
25 # Affichage des poids appris
26 weights2 = model2.layers[0].get_weights()[0]
27 bias2 = model2.layers[0].get_weights()[1]
28
29 no.nd(f"Précision du modèle : {acc_keras2:.2%}\n\nPoids pour 'en_freq' : {weights2[0]
[0]:.4f}\n\nPoids pour 'th_freq' : {weights2[1][0]:.4f}\n\nBiais : {bias2[0]:.4f}")

```



```

1 def build_and_train_lang_classif(X, y):
2     # building the "model"
3     single_neuron = nn.Linear(3, 1)
4     activation = nn.Sigmoid()
5
6     # training
7     opt = torch.optim.SGD(single_neuron.parameters(), lr=0.1)
8     loss_fn = nn.BCELoss() #nn.BCEWithLogitsLoss()
9     y_col = y.unsqueeze(1)
10
11     for _ in range(10):
12         opt.zero_grad()
13         loss = loss_fn(activation(single_neuron(X)), y_col)
14         loss.backward()
15         opt.step()
16
17     # pseudo-evaluation
18     with torch.no_grad():
19         acc = ((torch.sigmoid(single_neuron(X)) > 0.5).float() ==
20                y_col.float()).mean().item()
21         return single_neuron, acc
22
23     classif_pytorch, acc_pt = build_and_train_lang_classif(
24         torch.tensor(X3_lang, dtype=torch.float32),
25         torch.tensor(y_lang, dtype=torch.float32)
26     )

```

Outline

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les *losses*

fonctions de loss

Descente de gradient

TALA536B

Pierre Magistry –
ERTIM

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron


Quelques mots sur les *losses*

fonctions de loss

Descente de gradient

Au delà du perceptron

Modèle de base



Comment avoir plus de deux langues ?

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron


Quelques mots sur les losses

fonctions de loss

Descente de gradient

Au delà du perceptron

Modèle plus large



combien de paramètres ?

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron


Quelques mots sur les losses

fonctions de loss

Descente de gradient

Au delà du perceptron

ou plus profond : le perceptron multicouches (MLP)



combien de paramètres ?

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les losses

fonctions de loss

Descente de gradient

Un mot sur les tenseurs

cf

https://docs.pytorch.org/tutorials/beginner/blitz/tensor_tutorial.html

TALA536B

Pierre Magistry –
ERTIM

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les losses

Fonctions de loss

Découverte de gradient

Variabilité des résultats ?

- d'où vient le hasard
- init, epochs

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les losses

fonctions de loss

Descente de gradient

Quelques mots sur les NN en programmation Orientée Objet

- pytorch
 - keras
- MLP.parameters

TALA536B

Pierre Magistry –
ERTIM

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les losses

fonctions de loss

Descente de gradient

loss BCE vs. BCEwithLogits

TALA536B

Pierre Magistry –
ERTIM

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les losses

fonctions de loss

Descente de gradient

Outline

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les *losses*

fonctions de loss

Descente de gradient

TALA536B

Pierre Magistry –
ERTIM

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les *losses*

fonctions de loss

Descente de gradient

Losses et fonctions de décision

cf. Goldberg, chapitre 2

Avec un vecteur de sortie, il faut adapter

- ▶ la fonction de coût
- ▶ la prise de décision

TALA536B

Pierre Magistry –
ERTIM

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les *losses*
fonctions de loss

Descente de gradient

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les *losses*fonctions de *loss*

Descente de gradient

Ce dont on dispose

- ▶ en données d'entraînement un ensemble de couples (x_i, y_i)
- ▶ une fonction à paramétrer $\hat{y} = f(x; \theta)$

Ce que l'on veut

- ▶ trouver les meilleurs paramètres θ pour que les $\hat{y}$ correspondent au y
- ▶ au moyen d'une fonction de *Loss* $L(\hat{y}, y)$ qui mesure l'écart entre la prédiction et la bonne réponse
- ▶ une façon d'ajuster θ en fonction de $L(\hat{y}, y)$

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les *losses*

fonctions de loss

Descente de gradient

Sur l'ensemble du corpus, elle donne une idée de la qualité du paramétrage

$$\mathcal{L}(\theta) = \frac{1}{n} \sum_{i=1}^n L(f(x_i, \theta), y_i)$$

Nouvel objectif : minimiser la *loss* globalement

$$\hat{\theta} = \operatorname{argmin}_{\theta} \mathcal{L}(\theta) = \operatorname{argmin}_{\theta} \frac{1}{n} \sum_{i=1}^n L(f(x_i, \theta), y_i)$$

Point d'étape

$$\hat{\theta} = \underset{\theta}{\operatorname{argmin}} \mathcal{L}(\theta) = \underset{\theta}{\operatorname{argmin}} \frac{1}{n} \sum_{i=1}^n L(f(x_i, \theta), y_i)$$




Figure 1.9 The loss score is used as a feedback signal to adjust the weights.

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les *losses*

fonctions de *loss*

Descente de gradient

Outline

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les *losses*

fonctions de loss

Descente de gradient

TALA536B

Pierre Magistry –
ERTIM

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les *losses*

fonctions de loss

Descente de gradient

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les losses

fonctions de loss

Descente de gradient

Erreur quadratique moyenne (MSE)

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les losses

fonctions de loss

Descente de gradient

Binary crossentropy

(ou *logistic loss*)

Pour deux classes, avec une sortie entre 0 et 1 (choix d'une sigmoïde en activation) et des classes encodées 0 ou 1.

La sortie $\hat{y}$ s'interprète alors comme : $\hat{y} = P(y = 1|x)$. et la loss est définie par l'entropie :

$$BCE(\hat{y}, y) = -y \log(\hat{y}) - (1 - y) \log(1 - \hat{y})$$

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les losses

fonctions de loss

Descente de gradient

Categorical Cross-entropy

Utilisée quand la sortie est une *distribution de probabilité* sur l'ensemble des classes possibles.

y est alors un vecteur représentant cette distribution (sa longueur correspond donc au nombre de classes).

La fonction *softmax* permet d'obtenir un vecteur $\hat{y}$ dont toutes les valeurs sont entre 0 et 1 et somment à 1.

$$CCE(\hat{y}, y) = - \sum_i y_i \log(\hat{y}_i)$$

Outline

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les *losses*
fonctions de loss

Descente de gradient

TALA536B

Pierre Magistry –
ERTIM

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les *losses*
fonctions de loss

Descente de gradient

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les losses

fonctions de loss

Descente de gradient

Objectif

On peut maintenant mesurer si un paramétrage est bon ou mauvais. Mais il faut maintenant trouver le argmin_{θ}

Stratégie d'optimisation

- ▶ Étant donné un ensemble de paramètres
- ▶ on les ajuste pour avoir une *Loss* un peu meilleure
- ▶ et on recommence...

Intuition

- ▶ Voir le notebook `optimisation.py`
- ▶ Chercher les paramètres “à la main”
- ▶ en utilisant ou non les informations sur la loss
- ▶ (imaginer avec des millions de paramètres...)

Mais l'algorithme d'optimisation ne voit pas tout ça

À quelle information a-t-il accès ?

- ▶ La loss
- ▶ les dérivées partielles (les pentes)

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les losses

Fonctions de loss

Descente de gradient

Quelles dérivées dans des cas plus complexes ?

TALA536B

Pierre Magistry –
ERTIM

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les losses

fonctions de loss

Descente de gradient

Cas simple connus

- ▶ Les briques élémentaires des réseaux de neurones sont des fonctions **dérivables**
- ▶ aux dérivées connues

La *Chain Rule* pour les combiner

- ▶ Les réseaux complexes ne font que composer les briques élémentaires



$$\frac{d}{dx}f(g(x)) = f'(g(x)) \cdot g'(x)$$

- ▶ (voir la vidéo des matériaux complémentaires)

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les losses

Fonctions de loss

Descente de gradient

Forward-Backward algorithm

- ▶ Calculer la loss étant donné θ (forward)
- ▶ faire remonter les dérivées en “décomposant” le réseau avec la *chain rule* (backward)
- ▶ ajuster les paramètres θ en fonction des dérivées
- ▶ recommencer

Séance 1

Introduction

Généralités et révisions

Programme du semestre

Perceptrons

Séance 2

Corrections TP

Au delà du perceptron

Quelques mots sur les losses
fonctions de loss

Descente de gradient

En pratique il reste quelques problèmes à résoudre

- ▶ dans quelle mesure faire varier les poids ($\rightarrow$ *learning rate*)
- ▶ Pour tout le corpus ? Pour chaque exemple ? ($\rightarrow$ *batch*)
- ▶ $\rightarrow$ mini-batch SGD